

Reconocimiento de actividades que involucran la marcha.

Luis Guillermo Rodríguez López

12/04/23

lrodriguez@cicese.edu.mx

1 Introducción

El reconocimiento de actividades y/o acciones, es el proceso de inferir y asignar una etiqueta de clase a un elemento o instancia de un dataset de vídeo, imágenes, etc. El propósito de este documento es presentar los resultados obtenidos por dos clasificadores de ML, a saber, Naive Bayes y Support Vector Machine, cuya tarea fue clasificar tres tipos de actividades sensadas: subir escaleras, bajar escaleras y caminar en piso plano. Si bien los resultados obtenidos no fueron excelentes, se consideran buenos dentro de este ámbito.

2 Métodos

Para realizar la parte del sensado de las tres actividades mencionadas arriba, se utilizó un Inertial Measurement Unit (IMU) Devices, en específico, LPMS-B2 Series. Este dispositivo tiene tres tipos de sensores, un acelerómetro, un giroscopio y un magnetómetro. Este dispositivo se ajustó de forma sagital en el tobillo del pie derecho, más precisamente cerca del astrágalo como se muestra en Figure 1.

Figure 1: Sensor IMU puesto en el pie derecho.



2.1 Sensado

Una vez ajustado el sensor, fueron tomados los datos de cada persona al subir-bajar escaleras y caminar en un piso plano. El sensor genera un archivo csv con seis tipos de "señales crudas" como se muestran en Table 1. Durante el sensado de cada actividad realizada por cada persona, se hacía que el dispositivo dejara de capturar datos cada seis pasos del pie derecho (lugar del sensor), por lo que todas las actividades fueron realizadas en ese número de pasos. Dado que el sensado fue realizado en tres personas con doce repeticiones por actividad, se obtuvieron un total de 108 archivos, siendo este un número "relativamente bajo" para generar un modelo de ML. La idea que surgió fue segmentar toda la caminata (actividad) por cada número de pasos (seis), así la actividad quedaría representada por pasos, además de generar más archivos, es decir, seis subtablas como Table 1, cada una correspondientes a cada paso. Realmente cada segmento de tabla, y por ende de las seis señales, corresponden a un movimiento desde que el pie derecho despegó del suelo, pasando por apoyarnos en el pie izquierdo, hasta volver a poner el pie derecho en el suelo, es decir, contemplamos el movimiento del pie izquierdo.

AcX	AcY	AcZ	GyrX	GyrY	GyrZ
-0.042	-0.99	0.18	-0.062	0.40	-0.31
-0.04	-0.99	0.18	-0.20	0.59	-0.39
-0.04	-0.99	0.18	-0.32	0.45	-0.46
.
.
.

Table 1: Señales que contiene cada archivo csv.

Figure 2: Bajar escalera.



Figure 3: Caminar en piso plano.



2.2 Segmentación

Aunque la segmentación previamente descrita generaría un total 648 nuevos archivos, sin embargo, se debe tener en cuenta un criterio adecuado para realizar esta segmentación. Como segunda observación es descartar la segmentación inicial y final de la actividad, ya que al iniciar no hay movimiento del pie izquierdo y finalizar el pie izquierdo queda al parejo del pie derecho, algo comúnmente realizado en este ámbito.

Al momento de graficar las señales obtenidas por el sensor, se notó la existencia de un patrón muy bien definido en la componente Y del giroscopio (GyrY), en la cuál podemos ver seis valles correspondiente a los seis pasos realizados por la persona durante esa actividad (Ver Figure 4), por lo que un criterio apropiado para segmentar todo el archivo (y así las seis señales), fue usar esta señal como guía. Para realizar el segmentado del archivo se tomó como referencia los seis puntos máximos localizados (uno en cada cresta) en la señal GyrY, y en donde cada corte se tomó como el punto medio

entre cada máximo localizado, como por ejemplo en Figure 5.

Figure 4: Picos (máximos) de referencia.





Figure 5: Segmentación de la señal en pasos.



Sabemos de la literatura y por lo que podemos ver en las figuras antes mencionadas, el primer y último paso presentan cierto ruido que no permite segmentarlos de una forma adecuada (lo cual tiene que ver con el movimiento del pie izquierdo) por lo que se utilizaron los cuatro pasos intermedios y estos a su vez se etiquetaron con la etiqueta correspondiente al archivo segmentado.

2.3 Obtención de características

Después de haber aplicado la segmentación previamente descrita, observamos que el número de archivos crece, llegando a tener así 108 (archivos)

por 4 (archivos segmentados por pasos) archivos totales, es decir, 432 archivos (cada uno con las seis señales segmentadas).

Una vez obtenido el dataset de 432 filas por 6 columnas (las seis señales), se utilizó la librería TSFEL de python para la obtención de características de series temporales. Es importante mencionar que el dataset debe ser ingresado en su totalidad, ya que las columnas en conjunto proveen más características, además y dado que no se indicó el tipo de dominio del que se querían extraer las características, se obtuvieron todas.

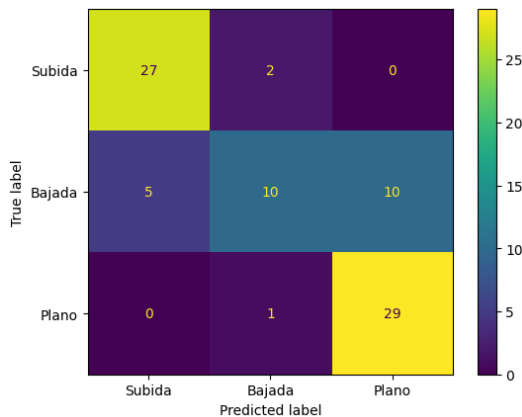
2.4 Clasificación

Cabe señalar que se obtuvo un total de 420 instancia y un número bastante grande de características, por lo que se decidió utilizar PCA para $n = 2$ como dataframe principal, debido a que este valor representaba más de un 95% de la varianza total. Para la parte de clasificación se utilizaron los algoritmos de aprendizaje supervisado Naive Bayes (NB) y Support Vector Machine (SVM) con un kernel lineal, realizando en cada uno una validación Hold-out y una validación cruzada (k-fold-cross validation) para $n = 5$ splits.

3 Resultados

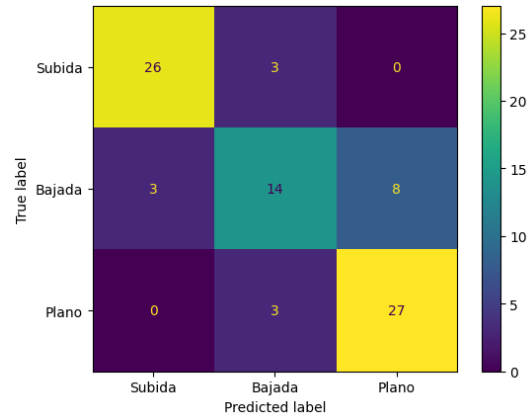
Al utilizar la validación Hold-out se obtuvo un accuracy del 78.57% en SVM, cuya matriz de confusión se puede ver en Figure 6, mientras que para NB se obtuvo un accuracy del 79.76% y cuya matriz de confusión correspondiente se puede ver en Figure 7.

Figure 6: Matriz de confusión de SVM para el dataframe PCA ($n = 2$).



(a) Observemos que se predicen 84 instancias.

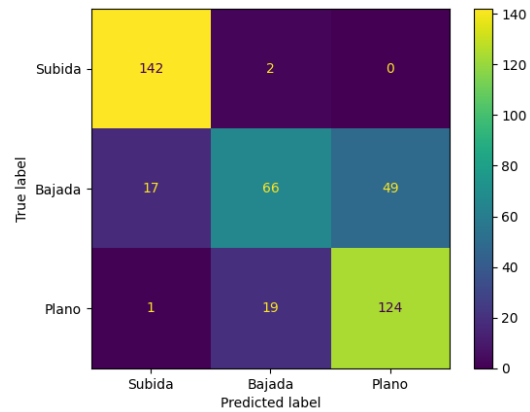
Figure 7: Matriz de confusión de NB para el dataframe PCA ($n = 2$).



(a) Observemos que se predicen 84 instancias.

Por otro lado, al utilizar la validación cruzada para $n = 5$ splits, se generaron 5 matrices de confusión para cada modelo, sin embargo, se incluye una matriz de confusión que relaciona la suma de cada celda de las 5 matrices, teniendo así las predicciones de las 420 instancias (Figure 8 y Figure 9).

Figure 8: Matriz de confusión suma de las matrices de confusión individuales de SVM para cada fold.




(a) Predicción de 420 instancias de PCA ($n = 2$).

4 Discusión y conclusiones

Al aplicar la validación cruzada se obtuvo, "en promedio", un accuracy del 79% para SVM, mientras que para NB se mantuvo justamente en el mismo porcentaje. Como se mencionó al inicio del documento, aunque los resultados no son excelentes, se consideran buenos, ya que están cerca de un 80% y, a lo mejor, con un número mayor de

Figure 9: Matriz de confusión suma de las matrices de confusión individuales de NB para cada fold.



(a) Predicción de 420 instancias de PCA ($n = 2$).

datos los resultados hubieran mejorado.

Cabe mencionar que se sensaron las actividades realizadas por cada persona pero llevando el sensor en la muñeca de la mano derecha, sin embargo, se pudo notar lo siguiente:

- la señal en GyrY es más caótica, es decir, se encuentran más picos (máximos) en un solo periodo de desplazamiento de la mano.
- aunado al punto previo, la señal en GyrY marca más o menos de seis valles dependiendo de la persona, lo cual causa un problema en la selección de picos (máximos).

Aunque los puntos anteriores son importantes, cabe mencionar que el comportamiento de uno de los participantes no fue el esperado en este sensado, ya que al momento de caminar, la persona movía brazo y pierna derecha al mismo tiempo, por lo que la actividad se tuvo que repetir varias veces.

Como trabajo futuro sería buena idea realizar el experimento general en más personas y, además, llevando el sensor en la mano, teniendo en mente alguna manera de evitar estos inconvenientes.

5 Referencias

References

López-Nava IH., Muñoz-Meléndez A., Pérez Sanpablo AI., Alessi Montero A., Quiñones Urióstegui I. & Núñez Carrera L. (2016) . *Estimation of temporal gait parameters using Bayesian models on acceleration signals*, Computer Methods in Biomechanics and Biomedical Engineering, 19:4, 396-403, DOI: 10.1080/10255842.2015.1032945.

Figure 10: Sensor puesto en la muñeca de la mano derecha.



López-Nava IH., Garcia-Constantino M. & Favela J. *Recognition of Gait Activities Using Acceleration Data from A Smartphone and A Wearable Device*, Proceedings 2019, 31, 60. <https://doi.org/10.3390/proceedings2019031060>.

López-Nava IH., Muñoz-Meléndez A. (2010) .*Towards Ubiquitous Acquisition and Processing of Gait Parameters*. In: Sidorov G, et al., editors. *Advances in artificial intelligence*. Lecture notes in computer science; Vol. 6437. Berlin: Springer; p.410-421.